

Введение в Data Science


Занятие 2. Линейные модели

Николай Анохин Михаил Фирулик

10 марта 2014 г.

ТЕХНОСФЕРА @mail.ru

Где мы находимся (глобально)



Где мы находимся (локально)

- M Выдвигаем гипотезу насчет **модели** - семейства параметрических функций вида

$$Y = \{y(x, \theta) : X \times \Theta \rightarrow T\},$$

которая могла бы решить нашу задачу (model selection)

- L Выбираем наилучшие параметры модели θ^* , используя **алгоритм обучения**

$$A(\mathbf{X}, \mathbf{T}) : (X, T)^N \rightarrow Y$$

(learning/inference)

- D Используя полученную модель $y^*(x) = y(x, \theta^*)$, классифицируем неизвестные объекты (decision making)

Как выбрать параметры модели?

Решить задачу оптимизации, чтобы получить значения θ^*

Варианты подходов

- ▶ θ – фиксировано, но неизвестно: ищем θ , согласующееся с обучающей выборкой
- ▶ θ – случайная величина, распределенная по известному закону: ищем параметры распределения

Обобщенные линейные модели

Метод максимального правдоподобия

Байесовский вывод

8 марта (is coming)



Setosa



Versicolor





Virginica

Задача

Определить вид ириса на основании длины чашелистика, ширины чашелистика, длины лепестка и ширины лепестка.

Ирисы Фишера



Линейные модели

Рассматривается случай 2 классов

Функция принятия решения

$$y(\mathbf{x}) = \mathbf{w}^\top \mathbf{x} + w_0$$


Регионы принятия решения

$$R_1 = \{\mathbf{x} : y(\mathbf{x}) > 0\}$$

$$R_2 = \{\mathbf{x} : y(\mathbf{x}) < 0\}$$

Задача

найти параметры модели \mathbf{w} , w_0



Линейные модели: наблюдения


Разделяющая поверхность

$$\mathcal{D} = \{\mathbf{x} : \mathbf{w}^\top \mathbf{x} + w_0 = 0\}$$

1. \mathbf{w} – нормаль к \mathcal{D}
2. $d = -\frac{w_0}{\|\mathbf{w}\|}$ – расстояние от центра координат до \mathcal{D}
3. $r(\mathbf{x}) = \frac{y(\mathbf{x})}{\|\mathbf{w}\|}$ – расстояние от \mathcal{D} до \mathbf{x}

Положим $x_0 \equiv 1$, получим модель

$$y(\tilde{\mathbf{x}}) = \tilde{\mathbf{w}}^\top \tilde{\mathbf{x}}$$



Обобщенные линейные модели

Линейная модель

$$y(\mathbf{x}) = w_0 + \sum w_i x_i$$

Квадратичная модель

$$y(\mathbf{x}) = w_0 + \sum w_i x_i + \sum \sum w_{ij} x_i x_j$$

Обобщенная линейная модель



$$g(\mathbf{x}) = \sum a_i \phi_i(\mathbf{x}) = \mathbf{a}^\top \mathbf{y}$$

Случай линейно разделимых классов

Обобщенная линейная модель

$$g(\mathbf{x}) = \sum a_i \phi_i(\mathbf{x}) = \mathbf{a}^\top \mathbf{y}$$

Дана обучающая выборка $\mathbf{Y} = \{\mathbf{y}_1, \dots, \mathbf{y}_N\}$



Идея

Преобразовать объекты второго класса в обратные им и решать задачу оптимизации в области $\mathbf{a}^\top \mathbf{y}_i > 0, \forall i$

Задача оптимизации

Задача

Минимизируем критерий $J(a)$ при условиях $a^T \mathbf{y}_i > 0, \forall i$

Пусть \mathcal{Y} – множество неправильно проклассифицированных объектов

- ▶ $J_e(a) = \sum_{\mathbf{y} \in \mathcal{Y}} 1$
- ▶ $J_p(a) = \sum_{\mathbf{y} \in \mathcal{Y}} -a^T \mathbf{y}$
- ▶ $J_q(a) = \sum_{\mathbf{y} \in \mathcal{Y}} (a^T \mathbf{y})^2$
- ▶ $J_r(a) = \sum_{\mathbf{y} \in \mathcal{Y}} \frac{(a^T \mathbf{y})^2 - b}{\|\mathbf{y}\|}$

Улучшение: добавить отступы

Градиентный спуск

```
1. initialise  $a$ ,  $J(a)$ ,  $\eta(k)$ ,  $\epsilon$ ,  $k = 0$   
2.   do  $k \leftarrow k + 1$   
3.      $a \leftarrow a - \eta(k) \nabla J(a)$   
4.   until  $\eta(k) \nabla J(a) < \epsilon$   
5. return  $a$   
5. end
```

Инкрементальный алгоритм

Рассматриваем $J_r(a) = \sum_{y \in \mathcal{Y}} \frac{(a^\top y)^2 - b}{\|y\|}$

1. initialise a , $\eta(k)$, $k = 0$
2. do $k \leftarrow k + 1$
3. if y_k is misclassified $a \leftarrow a - \eta(k) \frac{(a^\top y_k)^2 - b}{\|y_k\|^2} y_k$
4. until no errors left
5. return a
6. end

Случай линейно неразделимых классов

- ▶ Использовать $\eta(k) \rightarrow 0$ при $k \rightarrow \infty$
- ▶ От системы неравенств перейти к системе линейных уравнений
- ▶ Линейное программирование


Снова переобучение

Оптимизируем критерий с регуляризацией



$$J_1(a) = J(a) + \lambda J_R(a)$$

λ – коэффициент регуляризации

$$J_R(a) = \sum |a_j|^q$$



Перцептрон: результаты



Метод максимального правдоподобия

Задача

Дана обучающая выборка \mathbf{X} . Предполагая, что распределение $p(\mathbf{x}|\theta)$ известно, найти значения параметров θ .

Интуиция: найти такие θ , которые максимизируют вероятность $P(\mathbf{X}|\theta)$.

При предположении, что обучающие образцы независимы, имеем

$$P(\mathbf{X}|\theta) = \prod p(\mathbf{x}_i|\theta)$$

Функция правдоподобия

$$l(\theta) = \log P(\mathbf{X}|\theta) = \sum \log p(\mathbf{x}_i|\theta)$$

Требуется найти

$$\theta = \arg \max_{\theta} l(\theta)$$

Нормальное распределение

$$p(x|\mu) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

Задача

Дана выборка **X** объектов x , распределенных согласно одномерному нормальному закону $N(\mu, \sigma^2)$. Используя принцип максимального правдоподобия, оценить значение μ при известном значении σ .


Вероятностная линейная модель

Рассматриваем 2 класса

$$p(C_1|x) = \frac{p(x|C_1)p(C_1)}{p(x|C_1)p(C_1) + p(x|C_2)p(C_2)} = \frac{1}{1 + e^{-a}} = \sigma(a)$$

$$a = \ln \frac{p(x|C_1)p(C_1)}{p(x|C_2)p(C_2)}$$

$\sigma(a)$ – сигмоид-функция, $a = \ln(\sigma/(1 - \sigma))$



Упражнение: $p(\mathbf{x}|C_k) = \mathcal{N}(\mu_k, \Sigma)$. Проверить, что
 $p(C_k|x) = \sigma(\mathbf{w}^\top \mathbf{x} + w_0)$

(Еще более) обобщенная линейная модель

Базисные функции $\phi_n(\mathbf{x})$



$$\phi_n(\mathbf{x}) = \exp \left[-\frac{(\mathbf{x} - \mu_n)^2}{2s^2} \right]$$

Функция активации $f(a)$

$$f(a) = \sigma(a)$$

(Совсем) обобщенная линейная модель

$$y(\mathbf{x}, \mathbf{w}) = f(\mathbf{w}^\top \phi(\mathbf{x}))$$



Логистическая регрессия

дано

$$\{\phi_n = \phi(\mathbf{x}_n), t_n\}, \quad t_n \in \{0, 1\}, \quad n = 1 \dots N$$

модель

$$p(C_1|\phi) = y(\phi) = \sigma(\mathbf{w}^\top \phi)$$



функция правдоподобия

$$\begin{aligned} l(\mathbf{w}) &= \log \left[\prod_{n=1}^N p^{t_n}(C_1|\phi_n)(1 - p(C_1|\phi_n))^{1-t_n} \right] = \\ &= \sum_{n=1}^N t_n \log p(C_1|\phi_n) + (1 - t_n) \log(1 - p(C_1|\phi_n)) = -J_e(\mathbf{w}) \end{aligned}$$

градиент

$$\nabla J_e(\mathbf{w}) = \sum_{n=1}^N (p(C_1|\phi_n) - t_n) \phi_n \rightarrow \min_{\mathbf{w}}$$

Логистическая регрессия: результаты



Байесовский вывод

Дано

- ▶ плотность вероятности $p(\mathbf{x}|\theta)$
- ▶ априорная плотность $p(\theta)$
- ▶ выборка $\mathbf{X} = \{x_1, \dots, x_N\}$

Найти

апостериорную плотность $p(\theta|\mathbf{X})$

$$p(\mathbf{x}|\mathbf{X}) = \int p(\mathbf{x}|\theta)p(\theta|\mathbf{X})d\theta$$

$$p(\theta|\mathbf{X}) = \frac{p(\mathbf{X}|\theta)p(\theta)}{\int p(\mathbf{X}|\theta)p(\theta)d\theta}$$

$$p(\mathbf{X}|\theta) = \prod_n p(x_n|\theta)$$

Мультиклассовая классификация

Задача

Использовать бинарный линейный классификатор для мультиклассовой классификации Ирисов. Какие идеи?

Интерфейс классификатора `clf`

- ▶ Использовать выборку `x`, `y` для обучения
`clf.fit(x, y)`
- ▶ Предсказать класс объектов в `x`
`y = clf.predict(x)`
- ▶ Предсказать вероятности классов для `x`
`y = clf.predict_proba(x)`
- ▶ Вычислить значение функции решения в `x`
`d = clf.decision_function(x)`

Домашнее задание 1

Линейные модели

Реализовать на выбор

- ▶ Линейная классификация методом градиентного спуска
- ▶ Линейная регрессия методом градиентного спуска
- ▶ Линейная классификация инкрементальным методом
- ▶ Линейная регрессия инкрементальным методом

Ключевые даты

- ▶ До 2014/03/14 23.59 выбрать задачу и ответственного в группе
- ▶ До 2014/03/21 00.00 предоставить решение задания

Спасибо!

Обратная связь