#### Задача 1

Пусть имеется информация о покупках, совершаемых 100 миллионами людей, каждый из которых ходит в магазин в среднем 100 раз в году и покупает 10 из 1000 предложенных товаров. Предположим, что два человека попадают под подозрение, если они купили в течение года в точности один и тот же набор товаров (возможно, для изготовления бомбы?). С помощью принципа Бонферрони определите, будет ли эффективным метод выявления террористов, основанный на поиске таких пар людей.

# Задача 2


Рассмотреть смесь из D-мерных распределений Бернулли. В такой смеси  $\mathbf{x}$  – D-мерный бинарный вектор, каждый компонент  $x_i$  которого подчиняется распределению бернулли с параметром  $\mu_{ki}$  при заданном векторе  $\mu_k$ :

$$p(\mathbf{x}|\mu_k) = \prod_{i=1}^{D} \mu_{ki}^{x_i} (1 - \mu_{ki})^{(1-x_i)}$$

Вероятность k-го вектора  $\mu_k$  равна  $\pi_k$ . Выписать выражения для Е и М шагов при исользовании ЕМ алгоритма для нахождения неизвестных параметров  $\mu_k$  и  $\pi_k$ .

#### Задача 3

На рисунке показан набор из 10 точек, расположенных на прямой. Примените алгоритм иерархической кластеризации с single-link расстоянием между кластерами. Постройте дендрограмму.



Какова алгоритмическая сложность этого алгоритма?

## Задача 4

В таблице даны попарные расстояния между объектами из обучающей выборки. Проведите иерархическую кластеризацию с использованием complete-link расстояния между кластерами.

			$x_3$			
$\overline{x_1}$	0.0	1.5	5.0	4.0	2.5	0.5
$x_2$		0.0	4.0	0.5	3.5	2.0
$x_3$			0.0	6.0	2.0	1.0
$x_4$				0.0	5.5	4.5
$x_5$					0.0	1.0
$x_6$						0.0

## Задача 5

Пусть алгоритм, кластеризуюзщий точки в многомерном Евклидовом пространстве, оптимизирует критерий (k задано)

$$J = \frac{1}{2} \sum_{k} \sum_{x_i \in C_k} \sum_{x_j \in C_k} ||x_i - x_j||^2.$$

Покажите, что такой алгоритм эквивалентен стандартному алгоритму k-means.

#### Задача 6

Пусть даны 2 кластеризации C и  $\Omega$  одного и того же набора данных. Покажите, что

$$MI(C,\Omega) \le \frac{1}{2}(H(C) + H(\Omega)),$$

где  $MI(C,\Omega)$  – mutual information, а H(C) и  $H(\Omega)$  – соответствующие энтропии.

### Задача 7

Пусть дана обучающая выборка  $X_N$ , которая сгенерирована из распределения Стьюдента с неизвестными параметрами  $\mu$  и  $\sigma$  и известным количеством степеней свободы  $\nu$ . Используя принцип максимального правдоподобия, получите оценки для неизвестных параметров  $\mu$  и  $\sigma$ .