



ТЕХНОСФЕРА

Лекция 4 Задача классификации

Николай Анохин

15 октября 2014 г.

План занятия

Задачи классификации и регрессии

Подходы к моделированию

Теория принятия решений

Оценка результатов классификации

Деревья решений

Классификация: интуиция

Задача

Разработать алгоритм, позволяющий определить класс произвольного объекта из некоторого множества

- ▶ Дана *обучающая выборка*, в которой для каждого объекта известен класс




Регрессия: интуиция

Задача

Разработать алгоритм, позволяющий предсказать числовую характеристику произвольного объекта из некоторого множества

- ▶ Дана *обучающая выборка*, в которой для каждого объекта известно значение данной числовой характеристики



Постановка задачи

Пусть дан набор объектов $\mathcal{D} = \{(\mathbf{x}_i, y_i)\}$, $\mathbf{x}_i \in \mathcal{X}$, $y_i \in \mathcal{Y}$, $i \in 1, \dots, N$, полученный из неизвестной закономерности $y = f(\mathbf{x})$. Необходимо выбрать из семейства параметрических функций

$$H = \{h(\mathbf{x}, \theta) : \mathcal{X} \times \Theta \rightarrow \mathcal{Y}\}$$

такую $h^*(\mathbf{x}) = h(\mathbf{x}, \theta^*)$, которая наиболее точно аппроксимирует $f(\mathbf{x})$.

Задачи

- ▶ Классификация: $|\mathcal{Y}| < C$
- ▶ Регрессия: $\mathcal{Y} = \mathbb{R}$

Как решать

- M Выдвигаем гипотезу насчет **модели** - семейства параметрических функций вида

$$H = \{h(\mathbf{x}, \theta) : \mathcal{X} \times \Theta \rightarrow \mathcal{Y}\},$$

которая могла бы решить нашу задачу (model selection)

- L Выбираем наилучшие параметры модели θ^* , используя **алгоритм обучения**

$$A(X, Y) : (\mathcal{X}, \mathcal{Y})^N \rightarrow \Theta$$

(learning/inference)

- D Используя полученную модель $h^*(x) = h(x, \theta^*)$, классифицируем неизвестные объекты (decision making)

Виды моделей

Генеративные модели. Смоделировать $p(x|C_k)$ и $p(C_k)$, применить теорему Байеса

$$p(C_k|x) = \frac{p(x|C_k)p(C_k)}{p(x)}$$

и использовать $p(C_k|x)$ для принятия решения
(NB, Bayes Networks, MRF)

Дискриминативные модели. Смоделировать $p(C_k|x)$ и использовать ее для принятия решения
(Logistic Regression, Decision Trees)

Функции решения. Смоделировать напрямую $h^*(x) : \mathcal{X} \rightarrow \mathcal{Y}$
(Linear Models, Neural Networks)

Вероятностные модели VS Функции решения

- ▶ Отказ от классификации (reject option)
- ▶ Дисбаланс в выборке
- ▶ Ансамбли моделей
- ▶ Сильные предположения о природе данных
- ▶ Излишняя (вычислительная) сложность

Байесовский подход к моделированию

Обучение модели

$$LEARNING = representation + evaluation + optimization$$

Pedro Domingos

Evaluation – критерий, который оптимизируем

- ▶ эмпирический риск $\rightarrow \min$
- ▶ KL-дивергенция $\rightarrow \min$
- ▶ функция правдоподобия $\rightarrow \max$
- ▶ information gain $\rightarrow \max$

Optimization – как оптимизируем

- ▶ unconstrained (GD, Newton+)
- ▶ constrained (linear programming, quadratic programming)

Эмпирический риск

Функция потерь $\mathcal{L}(\mathbf{x}, y, \theta)$ - ошибка, которую для данного \mathbf{x} дает модель $h(\mathbf{x}, \theta)$ по сравнению с реальным значением y

Эмпирический риск – средняя ошибка на обучающей выборке

$$Q(X, Y, \theta) = \frac{1}{N} \sum_{n=1}^N \mathcal{L}(\mathbf{x}_n, y_n, \theta)$$

Задача – найти значение θ^* , минимизирующее эмпирический риск

$$\theta^* = \theta^*(X, Y) = \operatorname{argmin}_{\theta} Q(X, Y, \theta)$$

Некоторые функции потерь

- ▶ Индикатор ошибки

$$\mathcal{L}(\mathbf{x}, y, \theta) = 0 \text{ if } h(\mathbf{x}, \theta) = y \text{ else } 1$$

- ▶ Функция Минковского

$$\mathcal{L}(\mathbf{x}, y, \theta) = |y - h(\mathbf{x}, \theta)|^q$$

Частные случаи: квадратичная $q = 2$, абсолютная ошибка $q = 1$

- ▶ Hinge

$$\mathcal{L}(\mathbf{x}, y, \theta) = \max(0, 1 - y \times h(\mathbf{x}, \theta))$$





- ▶ Информационная

$$\mathcal{L}(\mathbf{x}, y, \theta) = -\log_2 p(y|\mathbf{x}, \theta)$$

Проблема 1. Переобучение

Задача





Аппроксимировать обучающую выборку полиномом M степени



Проблема 2. Проклятие размерности

Задача

Классифицировать объекты.



ТПР – Классификация

Пусть

\mathcal{R}_k – область, такая что все $x \in \mathcal{R}_k$ относим к C_k

Дано

R_{kj} – риск, связанный с отнесением объекта класса C_k к классу C_j

Найти

$\forall k : \mathcal{R}_k$, такие, что математическое ожидание риска $E[R]$ минимально.

$$E[R] = \sum_k \sum_j \int_{\mathcal{R}_j} R_{kj} p(C_k|x) p(x) dx$$

Медицинская диагностика

Матрица риска $[R_{kj}]$

	sick	normal
sick	0	10
normal	1	0

Условные вероятности $p(C_k|x)$

$$p(\text{normal}|\text{moving}) = 0.9, \quad p(\text{normal}|\text{not moving}) = 0.3$$

Вероятности $p(x)$

$$p(\text{moving}) = 0.7$$

Требуется определить $\mathcal{R}_{\text{sick}}, \mathcal{R}_{\text{normal}}$

ТПР – Регрессия

Те же виды моделей: **генеративные, дискриминативные, функция решения**

Задана функция риска

$$R(t, y(x))$$

Математическое ожидание $E[R]$

$$E[R] = \iint R(t, y(x)) p(x, t) dx dt$$

Для квадратичной функции риска $R(t, y(x)) = [t - y(x)]^2$

$$y(x) = E_t[t|x]$$

Как оценить различные модели?

Идея


использовать долю неверно классифицированных объектов
(error rate)

Важное замечание

error rate на обучающей выборке **НЕ** является хорошим показателем качества модели




Решение 1: разделение выборки

Делим обучающую выборку на **тренировочную**, **валидационную** и **тестовую**



Решение 2: скользящий контроль

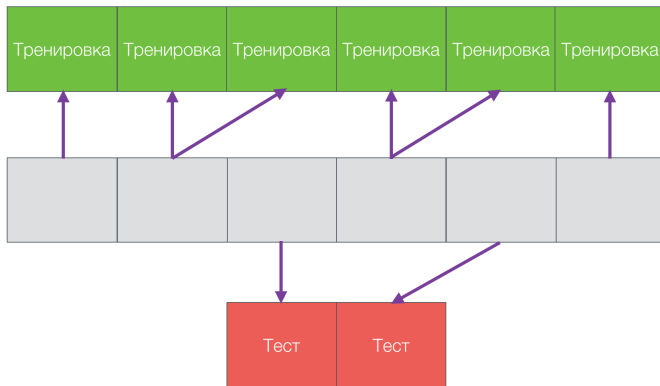
(n-times) (stratified) cross-validation



частный случай: leave-one-out

Решение 3: bootstrap

выбираем в тренировочную выбоку n объектов с возвращением



упражнение: найти математическое ожидание размера тестовой выборки.

Доверительный интервал для success rate

При тестировании на $N = 100$ объектах было получено 25 ошибок. Таким образом измеренная вероятность успеха (success rate) составила $f = 0.75$. Найти доверительный интервал для действительной вероятности успеха с уровнем доверия $\alpha = 0.8$.

Решение

Пусть p – действительная вероятность успеха в испытаниях бернулли, тогда

$$f \sim \mathcal{N}(p, p(1-p)/N).$$

Воспользовавшись табличным значением $P(-z \leq \mathcal{N}(0, 1) \leq z) = \alpha$, имеем

$$P\left(-z \leq \frac{f - p}{\sqrt{p(1-p)/N}} \leq z\right) = \alpha,$$

откуда

$$p \in \left(f + \frac{z^2}{2N} \pm z \sqrt{\frac{f}{N} - \frac{f^2}{N} + \frac{z^2}{4N^2}}\right) / \left(1 + \frac{z^2}{N}\right) = [0.69, 0.80]$$

Метрики качества. Вероятностные модели.

Пусть t_i - действительный класс для объекта x_i

- ▶ Information loss

$$-\frac{1}{N} \sum_i \log_2 p(t_i|x_i)$$

- ▶ Quadratic loss

$$\frac{1}{N} \sum_j (p(t_j|x_i) - a_j(x_i))^2,$$

где

$$a_j(x_i) = \begin{cases} 1, & \text{если } C_j = t_i \\ 0, & \text{иначе} \end{cases}$$

Метрики качества. Функции решения.

		Предсказанный	
		true	false
Действительный	true	TP	FN
	false	FP	TN

$$\text{success rate} = \text{accuracy} = \frac{TP + TN}{TP + FP + FN + TN}$$


$$\text{recall} = \text{TPR} = \frac{TP}{TP + FN}; \quad \text{precision} = \frac{TP}{TP + FP}$$

$$\text{FPR} = \frac{FP}{FP + TN}$$

$$\text{affinity} = \text{lift} = \frac{\text{accuracy}}{p}$$

Receiver Operating Characteristic

$$TPR = \frac{TP}{TP + FN}; \quad FPR = \frac{FP}{FP + TN}$$



Упражнение

Простые классификаторы

В генеральной совокупности существуют объекты 3 классов, вероятность появления которых $p_1 < p_2 < p_3$. Первый классификатор относит все объекты к классу с большей вероятностью (то есть к третьему). Второй классификатор случайно относит объект к одному из классов в соответствии с базовым распределением. Рассчитать precision и recall, которые эти классификаторы дают для каждого из 3 классов.

Метрики качества. Регрессия

$$MSE = \frac{1}{N} \sum (y(x_i) - t_i)^2, \quad RMSE = \sqrt{MSE}$$

$$MAE = \frac{1}{N} \sum |y(x_i) - t_i|, \quad RMAE = \sqrt{MAE}$$

$$RSE = \frac{\sum (y(x_i) - t_i)^2}{\sum (t_i - \bar{t})^2}$$

$$correlation = \frac{S_{ty}}{S_t S_y}; \quad S_{ty} = \frac{\sum (y(i) - \overline{y(i)})(t_i - \bar{t})}{N - 1}$$

$$S_y = \frac{\sum (y(i) - \overline{y(i)})^2}{N - 1}; \quad S_t = \frac{\sum (t_i - \bar{t})^2}{N - 1}$$

NFLT

Задача

Дано:

обучающая выборка из профилей
нескольких десятков тысяч
человек

- ▶ пол (binary)
- ▶ возраст (numeric)
- ▶ образование (nominal)
- ▶ и еще 137 признаков
- ▶ наличие интереса к косметике

Задача:


Для рекламной кампании
определить, характеристики
людей, интересующихся
косметикой




Обама или Клинтон?

Decision Tree: The Obama-Clinton Divide

In the nominating contests so far, Senator Barack Obama has won the vast majority of counties with large black or highly educated populations. Senator Hillary Rodham Clinton has a commanding lead in less-educated counties dominated by whites. Follow the arrows for a more detailed split.




Хороший день для партии в гольф



Регионы принятия решений

Decision surface of a decision tree using paired features



Рекурсивный алгоритм

```
decision_tree( $\mathbf{X}_N$ ):  
    если  $\mathbf{X}_N$  удовлетворяет критерию листа:  
        создаем текущий узел  $N$  как лист  
        выбираем подходящий класс  $C_N$   
    иначе:  
        создаем текущий узел  $N$  как внутренний  
        разбиваем  $\mathbf{X}_N$  на подвыборки  
        для каждой подвыборки  $\mathbf{X}_j$ :  
             $n = \text{decision\_tree}(\mathbf{X}_j)$   
            добавляем  $n$  к  $N$  как ребенка  
    возвращаем  $N$ 
```

CART

Classification And Regression Trees

1. Как происходит разделение?
2. На сколько детей разделять каждый узел?
3. Какой критерий листа выбрать?
4. Как укоротить слишком большое дерево?
5. Как выбрать класс каждого листа?
6. Что делать, если часть значений отсутствует?

Чистота узла

Задача

Выбрать метод, позволяющий разделить узел на два или несколько детей наилучшим образом

Ключевое понятие – *impurity* узла.

1. Misclassification

$$i(N) = 1 - \max_k p(x \in C_k)$$

2. Gini

$$i(N) = 1 - \sum_k p^2(x \in C_k) = \sum_{i \neq j} p(x \in C_i) p(x \in C_j)$$

3. Информационная энтропия

$$i(N) = - \sum_k p(x \in C_k) \log_2 p(x \in C_k)$$

Теория информации

Количество информации \sim “степень удивления”

$$h(x) = -\log_2 p(x)$$

Информационная энтропия $H[x] = E[h(x)]$

$$H[x] = -\sum p(x) \log_2 p(x) \quad \text{или} \quad H[x] = -\int p(x) \log_2 p(x) dx$$

Упражнение

Дана случайная величина x , принимающая 4 значения с равными вероятностями $\frac{1}{4}$, и случайная величина y , принимающая 4 значения с вероятностями $\{\frac{1}{2}, \frac{1}{4}, \frac{1}{8}, \frac{1}{8}\}$. Вычислить $H[x]$ и $H[y]$.

Выбор наилучшего разделения

Критерий

Выбрать признак и точку отсечения такими, чтобы было максимально уменьшение *impurity*

$$\Delta i(N, N_L, N_R) = i(N) - \frac{N_L}{N} i(N_L) - \frac{N_R}{N} i(N_R)$$

Замечания

- ▶ Выбор границы при числовых признаках: середина?
- ▶ Решения принимаются локально: нет гарантии глобально оптимального решения
- ▶ На практике выбор *impurity* не сильно влияет на результат

Если разделение не бинарное

Естественный выбор при разделении на B детей



$$\Delta i(N, N_1, \dots, N_B) = i(N) - \sum_{k=1}^B \frac{N_k}{N} i(N_k) \rightarrow \max$$

Предпочтение отдается большим B . Модификация:

$$\Delta i_B(N, N_1, \dots, N_B) = \frac{\Delta i(N, N_1, \dots, N_B)}{-\sum_{k=1}^B \frac{N_k}{N} \log_2 \frac{N_k}{N}} \rightarrow \max$$

(gain ratio impurity)

Использование нескольких признаков



Практика

Задача

Вычислить наилучшее бинарное разделение корневого узла по одному признаку, пользуясь gini impurity.

№	Пол	Образование	Работа	Косметика
1	М	Высшее	Да	Нет
2	М	Среднее	Нет	Нет
3	М	Нет	Да	Нет
4	М	Высшее	Нет	Да
1	Ж	Нет	Нет	Да
2	Ж	Высшее	Да	Да
3	Ж	Среднее	Да	Нет
4	Ж	Среднее	Нет	Да

Когда остановить разделение

Split stopping criteria

- ▶ никогда
- ▶ использовать валидационную выборку
- ▶ установить минимальный размер узла
- ▶ установить порог $\Delta i(N) > \beta$
- ▶ статистический подход

$$\chi^2 = \sum_{k=1}^2 \frac{(n_{kL} - \frac{N_L}{N} n_k)^2}{\frac{N_L}{N} n_k}$$

Укорачиваем дерево

Pruning (a.k.a. отрезание ветвей)

1. Растим “полное” дерево T_0
2. На каждом шаге заменяем самый “слабый” внутренний узел на лист

$$R_\alpha(T_k) = \text{err}(T_k) + \alpha \text{size}(T_k)$$

3. Для заданного α из получившейся последовательности

$$T_0 \succ T_1 \succ \dots \succ T_r$$

выбираем дерево T_k , минимизирующее $R_\alpha(T_k)$

Значение α выбирается на основании тестовой выборки или CV

Какой класс присвоить листьям

1. Простейший случай:
класс с максимальным количеством объектов
2. Дискриминативный случай:
вероятность $p(C_k|x)$

Вычислительная сложность

Выборка состоит из n объектов, описанных m признаками

Предположения

1. Узлы делятся примерно поровну
2. Дерево имеет $\log n$ уровней
3. Признаки бинарные

Обучение. Для узла с k обучающими объектами:

Вычисление impurity по одному признаку $O(k)$

Выбор разделяющего признака $O(mk)$

Итог: $O(mn) + 2O(m\frac{n}{2}) + 4O(m\frac{n}{4}) + \dots = O(mn \log n)$

Применение. $O(\log n)$

Отсутствующие значения

- ▶ Удалить объекты из выборки
- ▶ Использовать отсутствие как отдельную категорию
- ▶ Вычислять impurity, пропуская отсутствующие значения
- ▶ Surrogate splits: разделяем вторым признаком так, чтобы было максимально похоже на первичное разделение

Surrogate split

$$c_1 : \quad x_1 = \begin{pmatrix} 0 \\ 7 \\ 8 \end{pmatrix}, \quad x_2 = \begin{pmatrix} 1 \\ 8 \\ 9 \end{pmatrix}, \quad x_3 = \begin{pmatrix} 2 \\ 9 \\ 0 \end{pmatrix}, \quad x_4 = \begin{pmatrix} 4 \\ 1 \\ 1 \end{pmatrix}, \quad x_5 = \begin{pmatrix} 5 \\ 2 \\ 2 \end{pmatrix}$$

$$c_2 : \quad y_1 = \begin{pmatrix} 3 \\ 3 \\ 3 \end{pmatrix}, \quad y_2 = \begin{pmatrix} 6 \\ 0 \\ 4 \end{pmatrix}, \quad y_3 = \begin{pmatrix} 7 \\ 4 \\ 5 \end{pmatrix}, \quad y_4 = \begin{pmatrix} 8 \\ 5 \\ 6 \end{pmatrix}, \quad y_5 = \begin{pmatrix} 9 \\ 6 \\ 7 \end{pmatrix}$$

primary split



$x_1, x_2, x_3, x_4, x_5, y_1, y_2, y_3, y_4, y_5$

first surrogate split




$x_3, x_4, x_5, y_1, y_2, y_3, y_4, y_5$
 x_1, x_2

*predictive association
 with primary split = 8*

Упражнение

Вычислить второй surrogate split

Задача о косметике



X_0 – возраст, X_4 – неоконченное высшее образование, X_6 – пол


Задачи регрессии

Impurity узла N

$$i(N) = \sum_{y \in N} (y - \bar{y})^2$$

Присвоение класса листьям

- ▶ Среднее значение
- ▶ Линейная модель



Кроме CART

ID3 Iterative Dichotomiser 3

- ▶ Только номинальные признаки
- ▶ Количество детей в узле = количество значений разделяющего признака
- ▶ Дерево растет до максимальной высоты

C4.5 Улучшение ID3

- ▶ Числовые признаки – как в CART, номинальные – как в ID3
- ▶ При отсутствии значения используются **все** дети
- ▶ Укорачивает дерево, убирая ненужные предикаты в правилах

C5.0 Улучшение C4.5


- ▶ Проприетарный

Решающие деревья. Итог

- + Легко интерпретируемы. Визуализация (ня!)
- + Любые входные данные
- + Мультикласс из коробки
- + Предсказание за $O(\log n)$
- + Поддаются статистическому анализу
- Склонны к переобучению
- Жадные и нестабильные
- Плохо работают при дисбалансе классов

Ключевые фигуры

- ▶ Claude Elwood Shannon
(Теория информации)
- ▶ Leo Breiman
(CART, RF)
- ▶ John Ross Quinlan
(ID3, C4.5, C5.0)



Вопросы