



ТЕХНОСФЕРА

Лекция 6 Линейные модели для классификации и регрессии

Николай Анохин

30 октября 2014 г.

План занятия

Линейная регрессия

Логистическая регрессия

Обобщенные линейные модели

Постановка задачи

Пусть дан набор объектов $\mathcal{D} = \{(\mathbf{x}_i, y_i)\}$, $\mathbf{x}_i \in \mathcal{X}$, $y_i \in \mathcal{Y}$, $i \in 1, \dots, N$, полученный из неизвестной закономерности $y = f(\mathbf{x})$. Необходимо выбрать из семейства параметрических функций

$$H = \{h(\mathbf{x}, \theta) : \mathcal{X} \times \Theta \rightarrow \mathcal{Y}\}$$

такую $h^*(\mathbf{x}) = h(\mathbf{x}, \theta^*)$, которая наиболее точно аппроксимирует $f(\mathbf{x})$.

Задачи

- ▶ Регрессия: $\mathcal{Y} = [a, b] \subset \mathbb{R}$
- ▶ Классификация: $|\mathcal{Y}| < C$

Линейная регрессия

Модель

$$y = h(\mathbf{x}, \theta) + \epsilon,$$

где ϵ – гауссовский шум


$$p(\epsilon) = \mathcal{N}(\epsilon|0, \beta^{-1}),$$

откуда

$$p(y|\mathbf{x}, \theta, \beta) = \mathcal{N}(y|h(\mathbf{x}, \theta), \beta^{-1}).$$

Предсказание

$$E[y|\mathbf{x}] = \int yp(y|\mathbf{x})dy = h(\mathbf{x}, \theta).$$



Линейная модель

простейшая модель

$$h(\mathbf{x}, \mathbf{w}) = w_0 + w_1 x_1 + \dots + w_M x_M = \sum_{j=0}^M w_j x_j$$



улучшенная модель

$$h(\mathbf{x}, \mathbf{w}) = \sum_{j=0}^M w_j \phi_j(\mathbf{x}) = \mathbf{w}^T \boldsymbol{\phi}(\mathbf{x}),$$

$\phi_j(\mathbf{x})$ – базисные функции, $\phi_0(\mathbf{x}) = 1$

примеры

$$\varphi_j(x) = x^j, \quad \varphi_j(x) = \exp \left\{ -\frac{(x - \mu_j)^2}{2s^2} \right\}$$



ML – функция правдоподобия

Дана обучающая выборка $\mathcal{D} = (X, Y)$ из N объектов (\mathbf{x}_n, y_n)

Функция правдоподобия

$$\begin{aligned}\log p(Y|X, \mathbf{w}, \beta) &= \sum_{n=1}^N \log \mathcal{N}(y_n | \mathbf{w}^T \phi(\mathbf{x}_n), \beta^{-1}) = \\ &= \frac{N}{2} \log \beta - \frac{N}{2} \log 2\pi - \frac{\beta}{2} \sum_{n=1}^N \{y_n - \mathbf{w}^T \phi(\mathbf{x}_n)\}^2 \rightarrow \max_{\mathbf{w}, \beta}\end{aligned}$$

Квадратичная функция потерь

$$E_D(\mathbf{w}) = \frac{1}{2} \sum_{n=1}^N \{y_n - \mathbf{w}^T \phi(\mathbf{x}_n)\}^2 \rightarrow \min_{\mathbf{w}}$$

ML – решение

$$\log p(Y|X, \mathbf{w}, \beta) = \frac{N}{2} \log \beta - \frac{N}{2} \log 2\pi - \frac{\beta}{2} \sum_{n=1}^N \{y_n - \mathbf{w}^T \phi(\mathbf{x}_n)\}^2 \rightarrow \max_{\mathbf{w}, \beta}$$

Градиент

$$\beta \sum_{n=1}^N \{y_n - \mathbf{w}^T \phi(\mathbf{x}_n)\} \phi(\mathbf{x}_n)^T = 0$$

Решение

$$\mathbf{w}_{ML} = \Phi^\dagger Y = (\Phi^T \Phi)^{-1} \Phi^T Y, \quad \frac{1}{\beta_{ML}} = \frac{1}{N} \sum_{n=1}^N \{y_n - \mathbf{w}_{ML}^T \phi(\mathbf{x}_n)\}^2,$$

где

$$\Phi = \begin{pmatrix} \phi_0(\mathbf{x}_1) & \dots & \phi_M(\mathbf{x}_1) \\ \phi_0(\mathbf{x}_2) & \dots & \phi_M(\mathbf{x}_2) \\ \dots & \dots & \dots \\ \phi_0(\mathbf{x}_N) & \dots & \phi_M(\mathbf{x}_N) \end{pmatrix}$$

Регуляризация

Функция потерь

$$E(\mathbf{w}, \lambda) = E_D(\mathbf{w}) + \lambda E_W(\mathbf{w}),$$

где (как и раньше)

$$E_D(\mathbf{w}) = \frac{1}{2} \sum_{n=1}^N \{y_n - \mathbf{w}^T \phi(\mathbf{x}_n)\}^2 \rightarrow \min_{\mathbf{w}},$$

плюс регуляризация

$$E_W(\mathbf{w}) = E_q(\mathbf{w}) = \sum_{j=1}^M |\mathbf{w}_j|^q$$

Зоопарк

- ▶ $q = 1$ – Lasso
- ▶ $q = 2$ – Ridge (байесовский вывод: $p(\mathbf{w}|\alpha) = \mathcal{N}(\mathbf{w}|0, \alpha^{-1}\mathbf{I})$)
- ▶ $E_W(\mathbf{w}) = \rho E_1(\mathbf{w}) + (1 - \rho)E_2(\mathbf{w})$ – Elastic Net

Логистическая регрессия

Ирисы Фишера



Setosa



Versicolor





Virginica

Задача

Определить вид ириса на основании длины чашелистика, ширины чашелистика, длины лепестка и ширины лепестка.

Ирисы Фишера



Многомерное нормальное распределение

$$\mathcal{N}(\mathbf{x}|\mu, \Sigma) = \frac{1}{(2\pi)^{D/2}} \frac{1}{|\Sigma|^{1/2}} \exp \left\{ -\frac{1}{2}(\mathbf{x} - \mu)^T \Sigma^{-1}(\mathbf{x} - \mu) \right\}$$

Параметры

D -мерный вектор средних

$D \times D$ -мерная матрица ковариации

$$\mu = \int \mathbf{x} p(\mathbf{x}) d\mathbf{x}$$

$$\Sigma = E[(\mathbf{x} - \mu)(\mathbf{x} - \mu)^T]$$


Генеративная модель

Рассматриваем 2 класса

$$p(y_1|x) = \frac{p(x|y_1)p(y_1)}{p(x|y_1)p(y_1) + p(x|y_2)p(y_2)} = \frac{1}{1 + e^{-a}} = \sigma(a)$$

$$a = \ln \frac{p(x|y_1)p(y_1)}{p(x|y_2)p(y_2)}$$

$\sigma(a)$ – сигмоид-функция, $a = \ln(\sigma/(1 - \sigma))$



Случай нормальных распределений

Пусть

$$p(\mathbf{x}|y_k) = \mathcal{N}(\mathbf{x}|\mu_k, \mathbf{\Sigma}),$$

тогда

$$p(y_1|\mathbf{x}) = \sigma(\mathbf{w}^T \mathbf{x} + w_0),$$

где

$$\mathbf{w} = \mathbf{\Sigma}^{-1}(\mu_1 - \mu_2)$$

$$w_0 = -\frac{1}{2}\mu_1^T \mathbf{\Sigma}^{-1}\mu_1 + \frac{1}{2}\mu_2^T \mathbf{\Sigma}^{-1}\mu_2 + \ln \frac{p(y_1)}{p(y_2)}$$

Аналогичный результат для любых распределений из экспоненциального семейства

Maximum Likelihood

$$p(y_1, \mathbf{x}) = p(y_1)p(\mathbf{x}|y_1) = \pi \mathcal{N}(\mathbf{x}|\mu_1, \mathbf{\Sigma})$$

$$p(y_2, \mathbf{x}) = p(y_2)p(\mathbf{x}|y_2) = (1 - \pi) \mathcal{N}(\mathbf{x}|\mu_2, \mathbf{\Sigma})$$

Функция правдоподобия

$$p(Y, X|\pi, \mu_1, \mu_2, \mathbf{\Sigma}) = \prod_{n=1}^N [\pi \mathcal{N}(\mathbf{x}|\mu_1, \mathbf{\Sigma})]^{y_n} [(1 - \pi) \mathcal{N}(\mathbf{x}|\mu_2, \mathbf{\Sigma})]^{1-y_n}$$

Максимизируя $\log p(Y, X|\pi, \mu_1, \mu_2, \mathbf{\Sigma})$, имеем

$$\pi = \frac{1}{N} \sum_{n=1}^N y_n = \frac{N_1}{N_1 + N_2},$$

$$\mu_1 = \frac{1}{N_1} \sum_{n=1}^N y_n \mathbf{x}_n, \quad \mu_2 = \frac{1}{N_2} \sum_{n=1}^N (1 - y_n) \mathbf{x}_n,$$

аналогично для $\mathbf{\Sigma}$

Обобщенная линейная модель

Базисные функции $\phi_n(\mathbf{x})$



$$\phi_n(\mathbf{x}) = \exp \left[-\frac{(\mathbf{x} - \mu_n)^2}{2s^2} \right]$$

Функция активации $f(a)$

$$f(a) = \sigma(a)$$

(Совсем) обобщенная линейная модель

$$y(\mathbf{x}, \mathbf{w}) = f(\mathbf{w}^\top \phi(\mathbf{x}))$$



Логистическая регрессия

Дано.

$$\mathcal{D} = \{\phi_n = \phi(\mathbf{x}_n), y_n\}, y_n \in \{0, 1\}, n = 1 \dots N$$

Модель.

$$p(y = 1|\phi) = \sigma(\mathbf{w}^T \phi)$$

функция правдоподобия (кросс-энтропия)

$$\begin{aligned} l(\mathbf{w}) &= \log \left[\prod_{n=1}^N p^{y_n}(y = 1|\phi_n)(1 - p(y = 1|\phi_n))^{1-y_n} \right] = \\ &= \sum_{n=1}^N y_n \log p(y = 1|\phi_n) + (1 - y_n) \log(1 - p(y = 1|\phi_n)) = -J_c(\mathbf{w}) \rightarrow \max_{\mathbf{w}} \end{aligned}$$

Градиент


$$\nabla J_c(\mathbf{w}) = \sum_{n=1}^N (p(y = 1|\phi_n) - y_n) \phi_n$$

Гессиан


$$\nabla^2 J_c(\mathbf{w}) = \sum_{n=1}^N p(y = 1|\phi_n)(1 - p(y = 1|\phi_n)) \phi_n \phi_n^T$$

Градиентный спуск

```
1 function gd(grad, a0, epsilon):  
2     initialise eta(k)  
3     k = 0  
4     a = a0  
5     do:  
6         k = k + 1  
7         a = a - eta(k) grad(a)  
8     until eta(k) grad(a) < epsilon  
9     return a
```



(a)



(b)

Добавление момента: $\mathbf{a}_{k+1} = \mathbf{a}_k - \eta_k \nabla J(\mathbf{a}_k) + \mu_k (\mathbf{a}_k - \mathbf{a}_{k-1})$

Метод Ньютона

$$J(\mathbf{a}) \approx J(\mathbf{a}_k) + \nabla J(\mathbf{a}_k)^T (\mathbf{a} - \mathbf{a}_k) + \frac{1}{2} (\mathbf{a} - \mathbf{a}_k)^T \nabla^2 J(\mathbf{a}_k) (\mathbf{a} - \mathbf{a}_k) \rightarrow \min_{\mathbf{a}}$$

$$\mathbf{a} = \mathbf{a}_k - \nabla^2 J(\mathbf{a}_k)^{-1} \nabla J(\mathbf{a}_k)$$

```
1 function newton(grad, hessian, a0, epsilon):
2     initialise eta(k)
3     k = 0
4     a = a0
5     do:
6         k = k + 1
7         g = grad(a)
8         H = hessian(a)
9         d = solve(H * d = -g) # find d = - inv(H) * g
10        a = a + eta(k) d
11    until convergence
12    return a
```

BFGS – использовать приближение $\nabla^2 J(\mathbf{a}_k)$ или $\nabla^2 J(\mathbf{a}_k)^{-1}$

Iterative Reweighted Least Squares

Градиент и Гессиан логистической регрессии в матричной форме

$$\nabla J_c(\mathbf{w}) = X^T(\sigma - Y)$$

$$\nabla^2 J_c(\mathbf{w}) = X^T S X = X^T \text{diag}\{\sigma_n(1 - \sigma_n)\} X$$

Обновление весов



$$\mathbf{w}_{k+1} = \mathbf{w}_k - (X^T S_k X)^{-1} X^T S_k \mathbf{z}_k,$$

$$\mathbf{z}_k = X \mathbf{w}_k + S_k^{-1}(Y - \sigma_k)$$

Минимизация

$$\sum_{n=1}^N S_{kn}(z_{kn} - \mathbf{w}^T x_n)^2$$

Логистическая регрессия: результаты



Обобщенные линейные модели

Линейные модели

Рассматривается случай 2 классов

Функция принятия решения

$$y(\mathbf{x}) = \mathbf{w}^\top \mathbf{x} + w_0$$


Регионы принятия решения

$$R_1 = \{\mathbf{x} : y(\mathbf{x}) > 0\}$$

$$R_2 = \{\mathbf{x} : y(\mathbf{x}) < 0\}$$

Задача

найти параметры модели \mathbf{w} , w_0



Линейные модели: наблюдения


Разделяющая поверхность

$$\mathcal{D} = \{\mathbf{x} : \mathbf{w}^\top \mathbf{x} + w_0 = 0\}$$

1. \mathbf{w} – нормаль к \mathcal{D}
2. $d = -\frac{w_0}{\|\mathbf{w}\|}$ – расстояние от центра координат до \mathcal{D}
3. $r(\mathbf{x}) = \frac{y(\mathbf{x})}{\|\mathbf{w}\|}$ – расстояние от \mathcal{D} до \mathbf{x}

Положим $x_0 \equiv 1$, получим модель

$$y(\tilde{\mathbf{x}}) = \tilde{\mathbf{w}}^\top \tilde{\mathbf{x}}$$



Обобщенные линейные модели

Линейная модель

$$y(\mathbf{x}) = w_0 + \sum w_i x_i$$

Квадратичная модель

$$y(\mathbf{x}) = w_0 + \sum w_i x_i + \sum \sum w_{ij} x_i x_j$$

Обобщенная линейная модель



$$g(\mathbf{x}) = \sum a_i \phi_i(\mathbf{x}) = \mathbf{a}^\top \mathbf{y}$$

Случай линейно разделимых классов

Обобщенная линейная модель

$$g(\mathbf{x}) = \sum a_i \phi_i(\mathbf{x}) = \mathbf{a}^\top \mathbf{y}$$

Дана обучающая выборка $\mathbf{Y} = \{\mathbf{y}_1, \dots, \mathbf{y}_N\}$



Идея

Преобразовать объекты второго класса в обратные им и решать задачу оптимизации в области $\mathbf{a}^\top \mathbf{y}_i > 0, \forall i$

Задача оптимизации

Задача

Минимизируем критерий $J(a)$ при условиях $a^T \mathbf{y}_i > 0, \forall i$

Пусть \mathcal{Y} – множество неправильно проклассифицированных объектов

- ▶ $J_e(a) = \sum_{\mathbf{y} \in \mathcal{Y}} 1$
- ▶ $J_p(a) = \sum_{\mathbf{y} \in \mathcal{Y}} -a^T \mathbf{y}$
- ▶ $J_q(a) = \sum_{\mathbf{y} \in \mathcal{Y}} (a^T \mathbf{y})^2$
- ▶ $J_r(a) = \sum_{\mathbf{y} \in \mathcal{Y}} \frac{(a^T \mathbf{y})^2 - b}{\|\mathbf{y}\|}$

Улучшение: добавить отступы

Случай линейно неразделимых классов

- ▶ Использовать $\eta(k) \rightarrow 0$ при $k \rightarrow \infty$
- ▶ От системы неравенств перейти к системе линейных уравнений
- ▶ Линейное программирование


Снова переобучение

Оптимизируем критерий с регуляризацией



$$J_1(a) = J(a) + \lambda J_R(a)$$

λ – коэффициент регуляризации

$$J_R(a) = \sum |a_j|^q$$



Перцептрон: результаты



Задача: Мультикласс классификация

- ▶ one-vs-rest

Строим K моделей, каждая соответствует одному классу

- ▶ one-vs-one

Строим $K(K - 1)/2$ моделей, каждая соответствует паре классов

Задача

- ▶ Скачать шаблон кода <http://bit.ly/1DvG6hh>

- ▶ Реализовать схему one-vs-one

- ▶ Нарисовать разделяющие поверхности на графиках
- ▶ Посчитать итоговую accuracy

Вопросы

