



# ТЕХНОСФЕРА

## Лекция 6 Линейные модели для классификации и регрессии

Николай Анохин

28 октября 2014 г.

# План занятия

Линейная регрессия

Логистическая регрессия

Обобщенные линейные модели

# Постановка задачи

Пусть дан набор объектов  $\mathcal{D} = \{(\mathbf{x}_i, y_i)\}$ ,  $\mathbf{x}_i \in \mathcal{X}$ ,  $y_i \in \mathcal{Y}$ ,  $i \in 1, \dots, N$ , полученный из неизвестной закономерности  $y = f(\mathbf{x})$ . Необходимо выбрать из семейства параметрических функций

$$H = \{h(\mathbf{x}, \theta) : \mathcal{X} \times \Theta \rightarrow \mathcal{Y}\}$$

такую  $h^*(\mathbf{x}) = h(\mathbf{x}, \theta^*)$ , которая наиболее точно аппроксимирует  $f(\mathbf{x})$ .

Задачи

- ▶ Регрессия:  $\mathcal{Y} = [a, b] \subset \mathbb{R}$
- ▶ Классификация:  $|\mathcal{Y}| < C$

# Линейная регрессия

Модель

$$y = h(\mathbf{x}, \theta) + \epsilon,$$

где  $\epsilon$  – гауссовский шум


$$p(\epsilon) = \mathcal{N}(\epsilon|0, \beta^{-1}),$$

откуда

$$p(y|\mathbf{x}, \theta, \beta) = \mathcal{N}(y|h(\mathbf{x}, \theta), \beta^{-1}).$$

Предсказание

$$E[y|\mathbf{x}] = \int yp(y|\mathbf{x})dy = h(\mathbf{x}, \theta).$$



# Линейная модель

простейшая модель

$$h(\mathbf{x}, \mathbf{w}) = w_0 + w_1 x_1 + \dots + w_M x_M = \sum_{j=0}^M w_j x_j$$



улучшенная модель

$$h(\mathbf{x}, \mathbf{w}) = \sum_{j=0}^M w_j \phi_j(\mathbf{x}) = \mathbf{w}^T \boldsymbol{\phi}(\mathbf{x}),$$

$\phi_j(\mathbf{x})$  – базисные функции,  $\phi_0(\mathbf{x}) = 1$

примеры

$$\varphi_j(x) = x^j, \quad \varphi_j(x) = \exp \left\{ -\frac{(x - \mu_j)^2}{2s^2} \right\}$$



# ML – функция правдоподобия

Дана обучающая выборка  $\mathcal{D} = (X, Y)$  из  $N$  объектов  $(\mathbf{x}_n, y_n)$

Функция правдоподобия

$$\begin{aligned}\log p(Y|X, \mathbf{w}, \beta) &= \sum_{n=1}^N \log \mathcal{N}(y_n | \mathbf{w}^T \phi(\mathbf{x}_n), \beta^{-1}) = \\ &= \frac{N}{2} \log \beta - \frac{N}{2} \log 2\pi - \frac{\beta}{2} \sum_{n=1}^N \{y_n - \mathbf{w}^T \phi(\mathbf{x}_n)\}^2 \rightarrow \max_{\mathbf{w}, \beta}\end{aligned}$$

Квадратичная функция потерь

$$E_D(\mathbf{w}) = \frac{1}{2} \sum_{n=1}^N \{y_n - \mathbf{w}^T \phi(\mathbf{x}_n)\}^2 \rightarrow \min_{\mathbf{w}}$$

# ML – решение

$$\log p(Y|X, \mathbf{w}, \beta) = \frac{N}{2} \log \beta - \frac{N}{2} \log 2\pi - \frac{\beta}{2} \sum_{n=1}^N \{y_n - \mathbf{w}^T \phi(\mathbf{x}_n)\}^2 \rightarrow \max_{\mathbf{w}, \beta}$$

Градиент

$$\beta \sum_{n=1}^N \{y_n - \mathbf{w}^T \phi(\mathbf{x}_n)\} \phi(\mathbf{x}_n)^T = 0$$

Решение

$$\mathbf{w}_{ML} = \Phi^\dagger Y = (\Phi^T \Phi)^{-1} \Phi^T Y, \quad \frac{1}{\beta_{ML}} = \frac{1}{N} \sum_{n=1}^N \{y_n - \mathbf{w}_{ML}^T \phi(\mathbf{x}_n)\}^2,$$

где

$$\Phi = \begin{pmatrix} \phi_0(\mathbf{x}_1) & \dots & \phi_M(\mathbf{x}_1) \\ \phi_0(\mathbf{x}_2) & \dots & \phi_M(\mathbf{x}_2) \\ \dots & \dots & \dots \\ \phi_0(\mathbf{x}_N) & \dots & \phi_M(\mathbf{x}_N) \end{pmatrix}$$



# Регуляризация

Функция потерь

$$E(\mathbf{w}, \lambda) = E_D(\mathbf{w}) + \lambda E_W(\mathbf{w}),$$

где (как и раньше)

$$E_D(\mathbf{w}) = \frac{1}{2} \sum_{n=1}^N \{y_n - \mathbf{w}^T \phi(\mathbf{x}_n)\}^2 \rightarrow \min_{\mathbf{w}},$$

плюс регуляризация

$$E_W(\mathbf{w}) = E_q(\mathbf{w}) = \sum_{j=1}^M |\mathbf{w}_j|^q$$

Зоопарк

- ▶  $q = 1$  – Lasso
- ▶  $q = 2$  – Ridge (байесовский вывод:  $p(\mathbf{w}|\alpha) = \mathcal{N}(\mathbf{w}|0, \alpha^{-1}\mathbf{I})$ )
- ▶  $E_W(\mathbf{w}) = \rho E_1(\mathbf{w}) + (1 - \rho)E_2(\mathbf{w})$  – Elastic Net

# Логистическая регрессия

## Обобщенные линейные модели

# Вопросы

